

¿El orden de las transacciones revela fraude?

La pregunta. El área de riesgos sostiene que los fraudes que se escapan tienen un patrón que no está en los montos sino en el orden de las operaciones. El motor actual resume cada ventana en variables agregadas, y esas variables tienen una propiedad incómoda: **son idénticas si se baraja la secuencia.**

La respuesta corta. El orden **sí** es información real —lo demostramos— pero **vale mucho menos de lo que esperábamos.** Un modelo de secuencias no supera al motor actual en ningún mecanismo, y sumárselo mejora la detección solo en milésimas. El único beneficio con magnitud defendible es otro: **28 % menos bloqueos a clientes legítimos** detectando prácticamente el mismo fraude.

Recomendación: PILOTO ACOTADO — Conservar el motor actual como decisión principal.

43 % DEL DESEMPEÑO SECUENCIAL SE PIERDE AL BARAJAR LA HISTORIA	0.951 AUC-PR DEL MOTOR ACTUAL — EL MEJOR MODELO INDIVIDUAL	+0.0013 LO ÚNICO QUE GANA AL SUMARLE LA SEÑAL DE ORDEN	-95 BLOQUEOS INDEBIDOS, A IGUAL EXHAUSTIVIDAD
--	--	--	--

1 · Qué medimos y con qué datos

Construimos un generador propio de transacciones porque la pregunta exige **contrastar mecanismos de fraude cuya dependencia del orden sea conocida.** Con datos reales esa dependencia es justamente lo que se desconoce: si el modelo secuencial gana, no hay forma de saber si ganó *porque* leyó el orden. El precio de esta decisión es que los resultados no dicen nada sobre el fraude real del banco; lo que queda demostrado es el **método.**

El conjunto tiene **260,158 transacciones** de 4,000 tarjetas a lo largo de 243 días, con 1.07 % de fraude. Se generaron cuatro mecanismos con dependencia del orden deliberadamente distinta, y — esto es lo importante — **comportamiento legítimo que se parece a cada uno:** rachas de microcompras online, compras grandes legítimas y viajes. Sin esos confusores, un umbral sobre el monto máximo resolvería el problema.

Protocolo temporal. La partición es por fecha global (70 / 15 / 15), nunca aleatoria: entrenamos con lo más antiguo y probamos con lo más reciente. El conjunto de prueba se abrió **una sola vez**, después de fijar arquitecturas, hiperparámetros y umbral. **Cinco controles ejecutados** en el cuaderno, más un script de verificación independiente que elimina el futuro del conjunto y reconstruye las variables —ninguna de las 16 cambia—, comprueban que ninguna ventana contiene información posterior al instante de decisión.

2 · Comparación común

Modelo	Qué ve	AUC-PR	Precisión	Exhaustividad	F1
A — línea base	Variables agregadas (motor actual)	0.9509	0.568	0.963	0.714
B — secuencial	Secuencia ordenada, sin agregados	0.8602	0.459	0.897	0.607
C — híbrido	Secuencia + atención + agregados	0.8574	0.496	0.875	0.633
A + B combinados	Ambos puntajes, mezcla ajustada en validación	0.9522	0.645	0.956	0.771

No reportamos exactitud: con 1.07 % de fraude, responder «todo es legítimo» acertaría el 98.9 % sin detectar nada. El resultado incómodo es que **el motor actual supera al modelo secuencial.** La sección 3 explica por qué eso no cierra la pregunta.




Figura 1 — Curvas precisión-exhaustividad e intervalos de confianza del 95 % por bootstrap sobre el conjunto de prueba.

3 · ¿El orden aporta? Dos pruebas de falsificación

Una mejora de métricas no demuestra que un modelo use el orden. Intentamos **refutar nuestra propia conclusión** con dos pruebas.

Prueba 1 — Permutación controlada

Barajamos el orden de la historia dentro de cada ventana **sin cambiar los eventos ni sus valores**. Las variables agregadas son invariantes a permutaciones, así que siguen idénticas: lo único que se destruye es la secuencia. Repetimos con cinco permutaciones distintas.

Un control que no es obvio. El modelo lee su predicción del estado de la última posición de la ventana, que es la transacción que se está calificando. Si al barajar movemos también esa posición, destruiríamos dos cosas a la vez: el orden *y* el acceso del modelo al evento que debe puntuar. La caída resultante sobreestimaría el aporte del orden. Por eso barajamos **solo la historia** y dejamos fijo el evento calificado. Sin ese control la caída medida sería de 90.2 % en lugar de 43.4 %: la diferencia es el artefacto que evitamos.

Resultado: el modelo B pierde **43.4 %** de su AUC-PR al barajar la historia. El modelo C solo pierde 21.9 %, y eso es coherente: C conserva las variables agregadas como red de seguridad, así que la permutación no puede dejarlo ciego del todo.




Figura 2 — Desempeño con el orden original frente al orden barajado. Las barras de error recorren las cinco permutaciones.

Prueba 2 — Desempeño por mecanismo de fraude

Elegimos esta prueba porque es **la única capaz de refutar** la conclusión en lugar de matizarla. Predijimos, antes de medir, que B ganaría en el mecanismo dependiente del orden y **no** en vaciado súbito, que construimos sin ninguna estructura temporal como control negativo.

Mecanismo	Fraudes	Tasa base	A	B	C	B – A
escalada_prueba	195	0.50 %	0.970	0.910	0.854	-0.060
rafaga_geografica	69	0.18 %	0.921	0.909	0.861	-0.012
vaciado_subito	27	0.07 %	0.889	0.206	0.459	-0.683
toma_gradual	166	0.42 %	0.837	0.645	0.710	-0.192

La tasa base es la prevalencia de cada fila y equivale al AUC-PR de un clasificador al azar. Cambia entre filas porque el número de fraudes de cada mecanismo es distinto, así que **los AUC-PR no se comparan entre filas**; sí se comparan los modelos dentro de una misma fila, que es lo que hace la columna B – A.

Lo que se confirmó: B se desploma en vaciado súbito (0.206 frente a 0.889 de A), exactamente como predijimos. Donde no hay orden, el modelo de orden no tiene nada que leer. Esa es la prueba de que B realmente está leyendo secuencia y no otra cosa.

Lo que se refutó: esperábamos que B *superara* a A en el mecanismo de escalada, y no ocurrió. Lo reportamos como falló.

La pregunta que ninguna de las dos responde

El comité no preguntó si el modelo secuencial es mejor, sino si el orden aporta información que los agregados **no capturan**. Que B pierda no significa que su señal sea redundante. Lo comprobamos combinando ambos puntajes con una mezcla ajustada **solo en validación**:

Al sumar la señal secuencial al motor actual, el AUC-PR pasa de **0.9509** a **0.9522** (+0.0013; IC 95 % [+0.0001, +0.0027]). El intervalo no cruza cero: la señal de orden **no es redundante**.

Pero detectable no es lo mismo que importante. Con casi 40,000 transacciones de prueba se detectan diferencias minúsculas, y confundir ambas cosas es la forma más común de exagerar un resultado. La mejora de +0.0013 en AUC-PR es de milésimas.

El criterio de relevancia no lo inventamos nosotros: es la moneda que fijó el comité. En la sección 5 se traduce a quetzales y a clientes molestados, y ahí se ve que **el dinero apenas se mueve** mientras que **los bloqueos indebidos sí bajan de forma apreciable**. Esa —y no la detección— es la razón por la que el orden podría valer la pena.

¿Cuánta historia hace falta?

Prueba de apoyo: con una sola transacción visible el modelo no tiene memoria ni orden. El desempeño satura muy pronto, lo que tiene una consecuencia operativa directa — no hace falta guardar ventanas largas.

Transacciones visibles	AUC-PR
1	0.3296
2	0.5627
3	0.6996
5	0.8159
10	0.8603
15	0.8588
20	0.8602

4 • Nuestra apuesta y su veredicto

Registramos la hipótesis en el repositorio **antes** de entrenar y de abrir el conjunto de prueba (archivo *HIPOTESIS_C.md*; el sello de tiempo del commit es la constancia). Apostamos a que fusionar agregados con una lectura atendida de la secuencia superaría al mejor de A y B por al menos **+0.02** de AUC-PR en validación.

Veredicto: la apuesta NO se cumple. El margen fue de **-0.0871** frente al +0.02 exigido. Lo reportamos tal como quedó.

El control experimental permite localizar el fallo: la atención por sí sola aportó +0.0296 sobre B, y añadir las variables agregadas aportó +0.0066 más. La idea de combinar era correcta — lo demuestra la mezcla de la sección 3 — pero **la fusión dentro de una red neuronal fue el vehículo equivocado**: una capa densa no explota 41 variables tabulares tan bien como lo hace un modelo de árboles.

5 • Dónde poner el umbral y cuánto vale

El comité fijó los costos: **Q4,200** por fraude no detectado y **Q180** por bloquear una transacción legítima. La asimetría es de **23 a 1**, así que el umbral no se elige maximizando F1 —eso trataría ambos errores como igual de graves, lo que aquí es falso— sino **minimizando el costo esperado**. El umbral se ajustó en validación y se aplicó sin cambios a prueba.

Escenario	Umbral	Fraudes que pasan	Bloqueos indebidos	Costo	Ahorro
No hacer nada	—	457	0	Q1,919,400	—
Solo motor actual (A)	0.002	17	335	Q131,700	Q1,787,700
Motor + señal de orden	0.761	20	240	Q127,200	Q1,792,200

Aquí está el hallazgo que importa. Sobre los 36 días del conjunto de prueba, añadir la señal de orden cambia el ahorro en apenas **Q4,500** (0.25 %): en dinero, es indistinguible de no hacer nada. Pero los bloqueos a clientes legítimos caen de **335 a 240** (28 % menos) mientras la exhaustividad se mantiene prácticamente igual (0.963 → 0.956).

La razón de esa asimetría es aritmética: un bloqueo indebido cuesta 23 veces menos que un fraude, así que evitar 95 bloqueos casi no mueve la cuenta. Pero son 95 clientes reales a los que no se les rechaza una compra, y ese beneficio no aparece en el AUC-PR ni en el balance. **El caso a favor del modelo secuencial es de experiencia del cliente, no de detección de fraude.**

Extrapolado a la cartera de 1.4 millones de tarjetas, el ahorro mensual total frente a no hacer nada sería de **Q516,302,979**, con 69,140 bloqueos indebidos y 5,762 fraudes que aún pasarían al mes.

Advertencia sobre esta cifra. La extrapolación es lineal: supone que 1.4 millones de tarjetas reales se comportan como las 4,000 simuladas. Es una cota indicativa para dimensionar la decisión, **no una promesa de ahorro**.




Figura 3 — Curva de costo en validación (izquierda; las líneas punteadas marcan los umbrales elegidos) y ahorro en prueba (derecha).

6 • Recomendación, errores y límites

Recomendación: PILOTO ACOTADO — Conservar el motor actual como decisión principal. El motor de agregados es y sigue siendo la columna vertebral: resuelve bien los fraudes cuyo indicio está en la magnitud y ningún modelo de los que probamos lo supera.

Lo que justificaría incorporar la señal secuencial **no es detectar más fraude** —eso no lo logra— sino **molestar a menos clientes detectando el mismo fraude**. Si el área de experiencia del cliente considera que 28 % menos rechazos indebidos vale el costo de mantener un segundo modelo en producción, el piloto se justifica. Si la prioridad es puramente reducir pérdidas por fraude, con la evidencia actual **no**.

Por qué el modelo secuencial no ganó por sí solo

La explicación más probable no es la arquitectura sino los **datos**: el entrenamiento contiene apenas ~1,900 transacciones fraudulentas. Las variables agregadas son conocimiento del dominio ya destilado por ingenieros; la red tendría que redescubrirlo desde cero con muy pocos ejemplos positivos. Esto es comprobable: si el volumen de fraude etiquetado creciera en un orden de magnitud, esta conclusión podría invertirse.

Un patrón de error concreto

Los bloqueos indebidos se concentran en **transacciones legítimas de monto alto**: el modelo penaliza el gasto atípico aunque sea real. En la práctica esto afecta desproporcionadamente a clientes que hacen compras grandes ocasionales —electrónica, viajes—, que suelen ser los de mayor valor para el banco. Es un argumento para no usar el puntaje como bloqueo automático en montos altos, sino como disparador de una verificación por segundo canal.

Límites de este estudio

1. **Los datos son sintéticos.** Reflejan nuestras hipótesis sobre cómo se comporta el fraude, no el fraude del banco.
2. **Un defecto de nuestro propio generador.** Las microcompras de sondeo y las rachas legítimas de suscripciones quedaron con distribuciones de monto distintas, así que se separan por nivel y no solo por orden. Eso sesga la prueba 2 a favor del motor de agregados. Es la primera corrección que haríamos.
3. **Una sola semilla** por variante; no medimos la variabilidad entre inicializaciones.
4. **El mecanismo de toma gradual resiste a todos los modelos.** La señal se reparte en decenas de transacciones y la ventana de 20 no cubre el episodio.
5. **15 episodios de fraude quedan repartidos entre dos bloques temporales.** No es fuga —ninguna transacción se evalúa con información posterior a sí misma— pero significa que una porción muy pequeña del fraude de prueba pertenece a un episodio iniciado antes del corte.

Los intervalos de confianza de este informe se calculan remuestreando **tarjetas completas**, no transacciones sueltas. El fraude llega en episodios correlacionados; tratarlos como observaciones independientes produciría intervalos artificialmente estrechos y nos llevaría a afirmar más de lo que los datos sostienen.

Qué cambiaría nuestra recomendación

1. Si en datos reales la permutación costara menos del 15 % del desempeño, no habría evidencia de que el orden aporta y bastaría el motor actual.
2. Si el costo de un bloqueo indebido subiera de Q180 a más de ~Q900, la asimetría 23:1 se estrecharía lo suficiente como para recalcular toda la decisión.
3. Si apareciera un mecanismo nuevo sin ejemplos etiquetados, ningún modelo supervisado lo vería: haría falta un componente no supervisado.

El siguiente paso

Ejecutar la permutación controlada y la prueba de complementariedad **sobre los datos reales del banco**. El procedimiento es directamente aplicable y no requiere entrenar nada nuevo desde cero: es una tarde de trabajo, no un proyecto. Hasta entonces, lo que este trabajo demuestra es el método, no una cifra de ahorro.

Matriz de evidencias

Guía de lectura: dónde está cada evidencia, qué concluimos y qué la limita.

Evidencia	Dónde aparece	Conclusión	Limitación
1 · Integridad de datos	§2–§3 del cuaderno; 5 controles + verificar_causalidad.py	260,158 transacciones, 1.07 % de fraude, partición temporal 70/15/15 sin fuga.	Datos sintéticos: la validez externa no está demostrada.
2 · Comparación común	§7, figura 2	AUC-PR: A 0.951 · B 0.860 · C 0.857 · A+B 0.952.	B no recibe agregadas; parte de la brecha es de representación.
3 · Valor del orden	§8 figura 3; §9 figura 4; §11.5	Barajar el orden cuesta 43 % del AUC-PR de B. B colapsa en el control sin orden, como se predijo.	B no supera a A en ningún mecanismo: el orden aporta, pero no basta solo.
4 · Apuesta del equipo	HIPOTESIS_C.md (pre-registrada); §6	Margen en validación -0.0871 frente al +0.02 exigido: NO se cumple.	Una sola semilla por variante; no se midió variabilidad entre semillas.
5 · Decisión económica	§11 figura 6	Umbral 0.761; ahorro de Q1,792,200 en 36 días.	Costos fijos y uniformes; extrapolación lineal a 1.4 M de tarjetas.
6 · Recomendación y límites	§12 análisis de error; §14	Complementar el motor actual, no reemplazarlo.	Confusor de sondeo mal calibrado (§12.3): sesga §9 a favor de A.

Informe generado automáticamente desde *artefactos/resultados.json*; ninguna cifra fue transcrita a mano. Cuaderno reproducible con semilla 20853. · Daniel Estrada (20853) · Hansel López (19026)