

Universidad del Valle de Guatemala

Facultad de Ingeniería

Deep Learning — Semestre 2, 2026

Proyecto 1 — Informe final

Monitoreo transaccional: detectar lo que el orden revela

Informe al Comité de Riesgos — Banco del Altiplano

Integrantes:

Daniel Estrada – 20853

Daniela Ramírez – 23053

Guatemala, 4 de septiembre de 2026

Resumen ejecutivo

El motor antifraude actual resume cada ventana en variables agregadas —monto promedio, conteo, monto máximo, diversidad de comercios—, y esas variables tienen una propiedad incómoda: son idénticas si se baraja la secuencia. Por construcción, el motor actual no puede ver orden. Este trabajo mide si el orden aporta información que los agregados no capturan.

La respuesta es **sí, pero vale mucho menos de lo esperado**. El modelo de secuencias no supera al motor actual en ningún mecanismo, y sumarle su puntaje mejora la detección en +0.0013 de AUC-PR: detectable, pero de milésimas. El único beneficio con magnitud defendible es otro: **28 % menos bloqueos a clientes legítimos** detectando prácticamente el mismo fraude. **Recomendación: piloto acotado** —conservar el motor actual como decisión principal e incorporar la señal secuencial solo si el objetivo es reducir molestias al cliente, no pérdidas por fraude.

1. Datos y protocolo temporal

1.1 Origen y composición

Construimos un generador propio (ruta A) porque la pregunta exige contrastar mecanismos **cuya dependencia del orden sea conocida**. Con datos reales esa dependencia es justamente lo que se desconoce: si el modelo secuencial gana, no hay forma de saber si ganó *porque* leyó el orden. El precio es que los resultados no dicen nada del fraude real del banco: lo que queda demostrado es el método.

El conjunto tiene **260,158 transacciones** de 4,000 tarjetas a lo largo de 243 días, con **1.07 % de fraude**. Cada secuencia son las últimas **K = 20** transacciones de una misma tarjeta en orden cronológico, y el modelo predice si la última —la que se está autorizando— es fraudulenta. Los cuatro mecanismos se diseñaron con dependencia del orden deliberadamente distinta:

Mecanismo	Patrón	Papel en el experimento
escalada_prueba	Microcompras crecientes y luego un cargo grande	Orden fuerte: aquí B debería ganar
rafaga_geografica	Compras presenciales en departamentos distantes	Orden parcial: ventaja moderada
vaciado_subito	Uno a tres cargos muy superiores al hábito	Sin orden: control negativo
toma_gradual	Deriva lenta de horario, comercio y monto	Orden difuso: fallo declarado de antemano

El generador produce además comportamiento legítimo que *se parece* a cada fraude —rachas de microcompras en suscripciones, compras grandes reales, viajes con cambio de departamento—. Sin esos confusores, un umbral sobre el monto máximo resolvería el problema y la comparación perdería sentido.

1.2 Partición temporal y controles contra fuga

La partición es **por fecha global, nunca aleatoria**: el 70 % más antiguo entrena, el 15 % siguiente valida y el 15 % más reciente prueba (cortes: 2025-06-20 y 2025-07-26). El conjunto de prueba se abrió **una sola vez**, después de fijar arquitecturas, hiperparámetros y umbral.

Tres controles sostienen que ninguna ventana contiene información posterior al instante de decisión: las variables agregadas se calculan con ventanas cerradas por la izquierda, que excluyen la propia transacción calificada; medias, desviaciones y medianas de imputación se estiman **solo con el bloque de entrenamiento**; y un script independiente (*verificar_causalidad.py*) borra el futuro del conjunto y reconstruye las variables sin que ninguna de las 16 cambie. El cuaderno ejecuta además cinco aserciones que lo detendrían si alguno fallara.

Conviene declarar una decisión de diseño: la ventana de una transacción de prueba puede incluir transacciones anteriores al corte. Eso **no es fuga** —en producción el historial del cliente existe en el instante de la decisión—; lo prohibido es mirar hacia adelante, y eso no ocurre en ningún punto.

2. Comparación común: A frente a B

2.1 Qué ve cada modelo

A — línea base sin orden. *Gradient boosting* sobre 41 variables agregadas de ventana (1 h, 24 h y 7 d) más los atributos de la transacción actual. Representa el motor que el banco ya tiene y es invariante a permutaciones por construcción.

B — modelo secuencial. Una GRU con capas de *embedding* para categoría, canal y departamento, sobre la secuencia ordenada de las últimas 20 transacciones. Elegimos GRU y no Transformer porque con secuencias de 20 pasos la atención sobre dependencias largas no aporta, y un Transformer necesitaría codificación posicional explícita para no ser él mismo invariante al orden, lo que arruinaría el experimento. **B no recibe ninguna variable agregada:** ve los mismos atributos que A resume, pero en bruto y en su posición.

La asimetría es intencional, pero introduce una limitación que declaramos: parte de la brecha entre A y B es de *representación* y no de orden, y por eso la conclusión sobre el valor del orden **no se apoya en esta comparación** sino en la sección 3. Para igualar el esfuerzo, A y B recibieron cada uno su propia rejilla de hiperparámetros, elegida por AUC-PR de validación.

2.2 Resultados

Modelo	Qué ve	AUC-PR	Precisión	Exhaust.	F1
A — línea base	Variables agregadas (motor actual)	0.9509	0.568	0.963	0.714
B — secuencial	Secuencia ordenada, sin agregados	0.8602	0.459	0.897	0.607
C — híbrido	Secuencia + atención + agregados	0.8574	0.496	0.875	0.633
A + B combinados	Ambos puntajes, mezcla ajustada en validación	0.9522	0.645	0.956	0.771

Precisión, exhaustividad y F1 se miden en el umbral por costo de la sección 5. **No reportamos exactitud:** con 1.07 % de fraude, responder «todo es legítimo» acertaría el 98.9 % sin detectar nada.

El resultado incómodo es que **el motor actual supera al modelo secuencial**. La sección siguiente explica por qué eso no cierra la pregunta.




Figura 1. Curvas precisión-exhaustividad e intervalos de confianza del 95 % por bootstrap sobre el conjunto de prueba. Los intervalos remuestran tarjetas completas, no transacciones sueltas: el fraude llega en episodios correlacionados y tratarlos como observaciones independientes daría intervalos artificialmente estrechos.

3. ¿El orden aporta? Dos pruebas de falsificación

Una mejora de métricas no demuestra que un modelo use el orden. Estas pruebas existen para intentar **refutar nuestra propia conclusión**.

3.1 Prueba 1 — Permutación controlada (obligatoria)

Barajamos el orden de la historia dentro de cada ventana sin cambiar los eventos ni sus valores. Las variables agregadas son invariantes a permutaciones, así que siguen idénticas: lo único que se destruye es la secuencia. Repetimos con cinco permutaciones distintas, porque una sola podría resultar afortunada.

Un control que no es obvio. El modelo lee su predicción del estado de la última posición de la ventana, que es la transacción calificada. Si al barajar moviéramos también esa posición, destruiríamos dos cosas a la vez: el orden y el acceso del modelo al evento que debe puntuar. Por eso barajamos **solo la historia**; sin ese control la caída medida sería de 90.2 %, más del doble de la real.

Resultado: B pierde 43.4 % de su AUC-PR; C solo 21.9 %, coherente con que conserva los agregados como red de seguridad. Muy por encima del umbral de 15 % fijado de antemano: **el orden es información real y B la está usando**.




Figura 2. Desempeño con el orden original frente al barajado. Las barras de error recorren las cinco permutaciones.

3.2 Prueba 2 — Desempeño por mecanismo de fraude (elegida)

Elegimos esta prueba porque es la única de la lista capaz de **refutar** la conclusión en lugar de matizarla. Predijimos, antes de medir, que B ganaría en el mecanismo dependiente del orden y no en *vaciado súbito*, construido sin estructura temporal como control negativo.

Mecanismo	Fraudes	Tasa base	A	B	C	B – A
escalada_prueba	195	0.50 %	0.970	0.910	0.854	-0.060
rafaga_geografica	69	0.18 %	0.921	0.909	0.861	-0.012
toma_gradual	166	0.42 %	0.837	0.645	0.710	-0.192
vaciado_subito	27	0.07 %	0.889	0.206	0.459	-0.683

La tasa base es la prevalencia de cada fila y equivale al AUC-PR de un clasificador al azar. Cambia entre filas, así que los AUC-PR **no se comparan entre filas**; si se comparan los modelos dentro de una misma fila, que es lo que hace la última columna.

Lo que se confirmó: B se desploma en *vaciado súbito* (0.206 frente a 0.889 de A), exactamente como predijimos. Donde no hay orden, el modelo de orden no tiene nada que leer; junto con la prueba 1, es la evidencia de que B lee secuencia y no otra cosa. **Lo que se refutó:** esperábamos que B superara a A en el mecanismo de escalada, y no ocurrió. Lo reportamos como falló.

Como apoyo recortamos la ventana visible: con una sola transacción el AUC-PR de B cae a 0.330 —sin memoria no hay orden— y satura en 0.860 desde 10 transacciones. No hace falta guardar ventanas largas.

3.3 La pregunta que ninguna de las dos responde

El comité no preguntó si el modelo secuencial es mejor, sino si el orden aporta información que los agregados **no capturan**. Que B pierda no significa que su señal sea redundante: un modelo puede ser peor y aun así aportar algo que el otro no tiene. La ambigüedad ya estaba en validación (A 0.950 frente a B 0.826), de modo que la pregunta no nació de mirar la prueba; el análisis, en cambio, si se añadió después de abrirla y así queda etiquetado en el cuaderno (§11.5). La mezcla y su umbral se ajustan **únicamente con validación**; la prueba solo se usa para reportar.

Lo medimos combinando ambos puntajes con una regresión logística sobre sus *logits*. Si el coeficiente de B fuera nulo o la mezcla no superara a A, la respuesta sería «no». El AUC-PR pasa de 0.9509 a 0.9522 (+0.0013; IC 95 % [+0.0001, +0.0027]): el intervalo no cruza cero, luego **la señal de orden no es redundante**. Pero **detectable no es lo mismo que importante**: con casi 40,000 transacciones de prueba se detectan diferencias minúsculas, y la mejora es de milésimas. El criterio de relevancia lo pusimos en la moneda que fijó el propio comité (sección 5).

4. La apuesta del equipo y su veredicto

Registramos la hipótesis en el repositorio **antes** de entrenar y de abrir el conjunto de prueba (archivo *HIPOTESIS_C.md*; el sello de tiempo del *commit* es la constancia): combinar el resumen agregado con una lectura *atendida* de la secuencia —GRU con atención aditiva concatenada con las variables agregadas— mejoraría el AUC-PR sobre el mejor de A y B. **Métrica de éxito declarada: al menos +0.02 de AUC-PR en validación.** El **control experimental** entrena tres variantes con el mismo presupuesto, partición y semilla: B (secuencia sola), C1 (secuencia + atención) y C2 = C (secuencia + atención + agregados); sin C1 no podríamos distinguir si una ganancia viene de la atención o de haberle dado a C las variables que a B se le negaron.

Veredicto: la apuesta no se cumple. El margen en validación fue de -0.0871 frente al +0.02 exigido. El control localiza el fallo: la atención por sí sola aportó +0.0296 sobre B y añadir los agregados +0.0066 más. La idea de combinar era correcta —lo demuestra la mezcla de la sección 3.3—, pero fusionar dentro de una red neuronal fue el vehículo equivocado: una capa densa no explota 41 variables tabulares tan bien como un modelo de árboles. El criterio secundario también falló: esperábamos que la atención señalara una transacción anterior del episodio en al menos el 60 % de los aciertos, y lo hace en 14.0 %. Hoy no sirve como explicación para el analista.

5. Umbral, costo y decisión económica

El comité fijó los costos: **Q4,200** por fraude no detectado y **Q180** por bloqueo indebido. La asimetría es de 23 a 1, así que el umbral no se elige maximizando F1 —eso trataría ambos errores como igual de graves— sino **minimizando el costo esperado**. Se ajustó en validación y se aplicó sin cambios a prueba.

Escenario	Umbral	Fraudes que pasan	Bloqueos indebidos	Costo	Ahorro
No hacer nada	—	457	0	Q1,919,400	—
Solo motor actual (A)	0.002	17	335	Q131,700	Q1,787,700
Motor + señal de orden	0.761	20	240	Q127,200	Q1,792,200

Aquí está el hallazgo que importa. Sobre los 36 días del conjunto de prueba, añadir la señal de orden cambia el ahorro en apenas Q4,500 (0.25 %): en dinero es indistinguible de no hacer nada. Pero los bloqueos a clientes legítimos caen de 335 a 240 (28 % menos) mientras la exhaustividad se mantiene prácticamente igual (0.963 → 0.956). La razón es aritmética: un bloqueo indebido cuesta 23 veces menos que un fraude, así que evitar 95 casi no mueve la cuenta —pero son 95 clientes reales a los que no se les rechaza una compra, y ese beneficio no aparece en el AUC-PR. **El caso a favor del modelo secuencial es de experiencia del cliente, no de detección de fraude.**

Extrapolado a la cartera de 1.4 millones de tarjetas, el ahorro mensual frente a no hacer nada sería de **Q516,302,979**, con 69,140 bloqueos indebidos y 5,762 fraudes que aún pasarían al mes. **Advertencia:** la extrapolación es lineal y supone que 1.4 millones de tarjetas reales se comportan como las 4,000 simuladas. Es una cota indicativa, no una promesa de ahorro.

6. Recomendación, patrón de error y límites

6.1 Recomendación

Piloto acotado; conservar el motor actual como decisión principal. No reemplazar: el motor de agregados resuelve bien los fraudes cuyo indicio está en la magnitud y ninguno de los modelos que probamos lo supera. Complementar solo bajo una condición clara: lo que justificaría incorporar la señal secuencial no es detectar más fraude —eso no lo logra— sino **molestar a menos clientes detectando el mismo**. Si el área de experiencia del cliente considera que 28 % menos rechazos indebidos vale el costo de mantener un segundo modelo en producción, el piloto se justifica; si la prioridad es reducir pérdidas, no.

Que B no ganara por sí solo se explica probablemente por los datos y no por la arquitectura: el entrenamiento tiene apenas unas 1,900 transacciones fraudulentas, y los agregados son

conocimiento del dominio ya destilado que la red tendría que redescubrir con muy pocos positivos. Con un orden de magnitud más de fraude etiquetado, la conclusión podría invertirse.

6.2 Un patrón de error concreto

Los bloqueos indebidos se concentran en **transacciones legítimas de monto alto**: el modelo penaliza el gasto atípico aunque sea real, y eso afecta sobre todo a quienes hacen compras grandes ocasionales —electrónica, viajes—, los clientes de mayor valor para el banco. Es un argumento para no usar el puntaje como bloqueo automático en montos altos, sino como disparador de una verificación por segundo canal. En el otro extremo, *toma gradual* resiste a los tres modelos: la señal se reparte en decenas de transacciones y la ventana de 20 no cubre el episodio; es el fallo que declaramos antes de medirlo.

6.3 Límites y qué cambiaría la recomendación

- **Los datos son sintéticos:** reflejan nuestras hipótesis sobre el fraude, no el del banco.
- **Un defecto de nuestro propio generador:** los sondeos y las rachas legítimas de suscripciones quedaron con montos distintos, así que se separan por nivel y no solo por orden. Eso sesga la prueba 2 a favor del motor de agregados y es la primera corrección que haríamos.
- **Una sola semilla por variante:** no medimos la variabilidad entre inicializaciones.
- **Qué cambiaría la recomendación:** que en datos reales la permutación costara menos del 15 % del desempeño (no habría evidencia de aporte del orden); que un bloqueo indebido pasara de Q180 a más de unos Q900 (la asimetría 23:1 se estrecharía y habría que recalcular todo); o que apareciera un mecanismo nuevo sin ejemplos etiquetados, invisible para cualquier modelo supervisado y que exigiría un componente no supervisado.

Siguiente paso. Ejecutar la permutación controlada y la prueba de complementariedad sobre los datos reales del banco: el procedimiento es directamente aplicable. Hasta entonces, lo que este trabajo demuestra es el método, no una cifra de ahorro.

7. Matriz de evidencias

Evidencia	Dónde aparece	Conclusión	Limitación
1 · Integridad de datos	§1; cuaderno §2–§3; <i>verificar_causalidad.py</i>	260,158 transacciones, 1.07 % de fraude, partición 70/15/15 por fecha, sin fuga.	Datos sintéticos: validez externa no demostrada.
2 · Comparación común	§2.2, tabla y figura 1	AUC-PR: A 0.951, B 0.860, C 0.857, A+B 0.952.	B no recibe agregadas: parte de la brecha es de representación.
3 · Valor del orden	§3.1 figura 2; §3.2 tabla; §3.3	Barajar cuesta 43 % del AUC-PR de B, que colapsa en el control sin orden. La mezcla A+B supera a A con IC que no cruza cero.	B no supera a A en ningún mecanismo: aporta, pero no basta solo.
4 · Apuesta del equipo	§4; <i>HIPOTESIS_C.md</i>	Margen -0.0871 frente al +0.02 exigido: no se cumple. La atención explica el caso en 14 %.	Una sola semilla por variante.
5 · Decisión económica	§5, tabla de escenarios	Umbral 0.761; Q1,792,200 de ahorro en 36 días. Frente a solo A: Q4,500 y 95 bloqueos menos.	Costos uniformes; extrapolación lineal a 1.4 M de tarjetas.
6 · Recomendación y límites	§6	Complementar con un piloto acotado, no reemplazar. El error se concentra en compras legítimas de monto alto.	Confusor de sondeo mal calibrado: sesga la prueba 2 a favor de A.

Generado desde *artefactos/resultados.json*; ninguna cifra transcrita a mano. Semilla 20853.