

¿El orden de las transacciones revela fraude?

Daniel Estrada (20853) · Hansel López (19026)

Proyecto 1 · Deep Learning 2026 · Universidad del Valle de Guatemala

La pregunta del comité

«Cuando revisamos los casos que se nos escaparon, el patrón siempre está ahí. No en los montos: **en el orden en que ocurrieron.**»

El motor actual resume cada ventana en variables agregadas: monto promedio de 24 h, transacciones por hora, monto máximo, diversidad de comercios.

El problema: todas esas variables son **idénticas si se baraja la secuencia**. Por construcción, el motor actual no puede ver orden.

Nuestra pregunta no es «¿puedo entrenar una LSTM?»

Es: ¿el orden aporta información que los agregados no capturan, y cuánto vale en quetzales?

Diseño: datos donde conocemos la verdad

Generamos los datos para poder hacer una **predicción falsable**: cuatro mecanismos con dependencia del orden **conocida y distinta**.

Mecanismo	Orden	Predicción
escalada de prueba	fuerte	B gana
ráfaga geográfica	parcial	empate
vaciado súbito	ninguno	B NO gana
toma gradual	difuso	ambos fallan

Confusores legítimos para que no sea trivial: rachas de microcompras, compras grandes reales, viajes.

Partición temporal estricta 70/15/15 por fecha. El conjunto de prueba se abrió **una sola vez**.

vaciado súbito es el control negativo. Si B ganara también ahí, la ventaja no vendría del orden.

Prueba 1 — Permutación controlada

Barajamos el orden de **la historia** dentro de cada ventana. Mismos eventos, mismos valores, mismas variables agregadas, y la transacción calificada se queda en su sitio. Solo se destruye la secuencia.

–43 %

del AUC-PR del modelo secuencial se pierde al barajar
(0.860 → 0.487, cinco permutaciones distintas)

Si barajáramos también la posición de la transacción calificada, el modelo perdería además el acceso al evento que debe puntuar y la caída parecería mayor de lo que es. **Ese control importa: sin él estaríamos midiendo dos cosas y atribuyéndolas al orden.**

Prueba 2 — Por mecanismo: el resultado incómodo

Mecanismo	A (agregados)	B (secuencial)	B – A
escalada_prueba	0.970	0.910	-0.060
rafaga_geografica	0.921	0.909	-0.012
vaciado_subito	0.889	0.206	-0.683
toma_gradual	0.837	0.645	-0.192

Se confirmó: B se desploma en el control sin orden (0.206 vs 0.889). Donde no hay orden, no hay nada que leer.

Se refutó: B **no supera** a A en ningún mecanismo. Nuestra predicción falló y así lo reportamos.

Entonces, ¿el orden aporta o no?

Que B **pierda** no significa que su señal sea **redundante**. Combinamos ambos puntajes (mezcla ajustada solo en validación):

0.9509

Motor actual solo

0.9522

Motor + señal de orden

+0.0013

IC 95 % [+0.0001, +0.0027] — no cruza cero

Detectable ≠ importante. El intervalo excluye el cero, así que la señal de orden no es redundante. Pero la mejora es de **milésimas**. Con 40,000 transacciones de prueba se detectan diferencias minúsculas; presentar esto como «las secuencias mejoran la detección» sería exagerar lo que medimos.

El criterio de relevancia lo puso el comité: quetzales. Siguiendo diapositiva.

La decisión en quetzales — y el hallazgo real

Costos del comité: **Q4,200** por fraude que pasa, **Q180** por bloqueo indebido. Asimetría **23 : 1**, así que el umbral minimiza costo esperado, no F1.

Escenario	Fraudes que pasan	Bloqueos indebidos	Ahorro en prueba
Solo motor actual	17	335	Q1,787,700
Motor + señal de orden	20	240	Q1,792,200

En dinero: nada. Q4,500 de diferencia (0.00 %). Indistinguible de no hacer nada.

En clientes: sí. 0 bloqueos indebidos menos (0 %) a igual exhaustividad.

El caso a favor del orden es de experiencia del cliente, no de detección de fraude. Un falso positivo cuesta 23 veces menos, así que evitar 0 de ellos casi no mueve el balance — pero son 0 personas a las que no se les rechaza una compra.

Recomendación y límites

Conservar el motor actual. Lo que justificaría el piloto no es detectar más fraude —eso no lo logra— sino molestar a menos clientes detectando el mismo.

Por qué B no ganó solo

Pocos fraudes etiquetados en entrenamiento. Los agregados son conocimiento del dominio ya destilado; la red debe redescubrirlo con muy pocos positivos. **Parece un límite de datos, no de arquitectura** — y eso es comprobable.

Nuestra apuesta C falló (-0.087 frente al $+0.02$ exigido). Pre-registrada en git antes de ver el test; la reportamos como quedó.

Límites que declaramos

- Datos sintéticos: no dicen nada del fraude real.
- **Defecto de nuestro propio generador:** los sondeos fraudulentos y las rachas legítimas se separan por monto, no solo por orden — eso sesga la prueba 2 a favor del motor de agregados.
- La atención de C explica el caso en apenas 14 % de las veces, frente al 60 % declarado. Hoy no sirve como explicación.
- Una sola semilla por variante.

Siguiente paso: correr la permutación y la prueba de complementariedad sobre los datos reales del banco. Es una tarde de trabajo.